

Raport z przedmiotu Pracownia Problemowa

Prognozowanie produkcji OZE (wiatr, fotowoltaika) w Polsce

Autorzy: Joanna Heřdak, Łukasz Sędej

Spis treści

- 1. Przygotowanie zbioru danych
- 2. Prognozowanie produkcji PV
- 3. Prognozowanie produkcji wiatrowej FW

1. Przygotowanie zbioru danych

1.1. Cel i źródła danych

Celem części projektu realizowanej w ramach Pracowni Problemowej było prognozowanie godzinowej produkcji energii ze źródeł odnawialnych (fotowoltaika – PV oraz farmy wiatrowe – FW) dla całej Polski. Horyzont prognozy wynosi **24 godziny**, a długość zbioru walidacyjnego to **5–7 dni**.

Wykorzystano dwa źródła danych:

Źródło	Zawartość
fw_pv.xlsx	Godzinowa łączna produkcja PV i FW dla całej Polski (dane PSE)
16 plików *.csv	Godzinowe dane pogodowe dla każdego z 16 województw

Plik fw_pv.xlsx zawiera dwie kolumny produkcji wyrażone w **MWh (megawatogodziny)** – jest to ilość energii wytworzonej w ciągu danej godziny przez wszystkie instalacje danego typu w Polsce łącznie. Ponieważ krok czasowy wynosi 1 godzinę, wartości te są równoważne średniej mocy w MW. Przedrostek **his-wlk-cal** oznacza *historical – large-scale calibrated* (dane historyczne skalibrowane na skalę krajową).

Dla każdego województwa dostępnych jest **9 zmiennych pogodowych**: temperatura powietrza, wilgotność względna, opady deszczu, opady śniegu, temperatura gleby, wilgotność gleby, prędkość wiatru, punkt rosy oraz promieniowanie słoneczne.


1.2. Czyszczenie danych produkcyjnych

W danych produkcji PV wykryto braki (wartości NaN):


- końcowe wiersze pliku (brak najnowszych odczytów) – zostały odcięte, aby nie tworzyć sztucznych trendów przez interpolację,
- pojedyncze braki w środku szeregu – uzupełniono interpolacją liniową.

Produkcja PV

Analiza wykazała, że przez **ok. 25% czasu produkcja PV wynosi blisko zero** (godziny nocne).



Na wykresie przebiegu czasowego widać duże spadki produkcji PV w miesiącach zimowych – trend ten powtarza się we wszystkich latach. Dodatkowo produkcja rośnie z roku na rok (najwyższe dni produkcyjne każdego kolejnego roku przewyższają rekordy z roku poprzedniego), co może wynikać najzwyczajniej z ilości instalacji fotowoltaicznych rosnącej z roku na rok.



oczekiwaniami produkcja PV koncentruje się w najbardziej nasłonecznionych godzinach dnia – im wyżej słońce, tym większa produkcja.

Zgodnie z

1.3. Inżynieria cech

Dane pogodowe 16 województw połączono z danymi produkcji po wspólnej kolumnie czasu (*Date*), stosując złączenie wewnętrzne (*inner join*), aby zachować tylko godziny z kompletem danych.

Następnie dodano:


- **cechy czasowe cykliczne** (kodowanie sin/cos): godzina doby, dzień roku, miesiąc, dzień tygodnia. Dzięki temu model traktuje np. godziny 23:00 i 00:00 jako sąsiednie, a nie skrajnie różne wartości,
- **flagi binarne**: czy noc / czy weekend,
- **agregaty krajowe** dla każdej zmiennej pogodowej: średnia (*PL_mean_**) i odchylenie standardowe (*PL_std_**) po wszystkich województwach.

Końcowy zbiór *dataset_full.csv* zawiera **10 853 wiersze i 179 kolumn**, obejmując okres od **2025-02-15** do **2026-05-13**. Zatem **177** cechy wejściowe modelu to:

Grupa cech	Liczba
Cechy pogodowe per województwo (16 × 9)	144
Agregaty krajowe (<i>PL_mean_*</i> , <i>PL_std_*</i>)	18
Cechy czasowe (cykliczne + flagi)	15

1.4. Eksploracja danych – korelacje

Produkcja PV



Analiza korelacji potwierdza, że średnie krajowe wartości pogodowe (zwłaszcza promieniowanie słoneczne) oraz cykliczne cechy czasowe są silnie powiązane z wielkością produkcji PV.

1.5. Podziały zbioru

Przygotowano dwa niezależne podziały danych:

Podział 1 – walidacja na ostatnich 7 dniach (standardowy test prognozy)

W przypadku predykcji pv zrealizowano:

Plik	Wiersze	Zakres
dataset_train.csv	10 684	2025-02-15 → 2026-05-06
dataset_val.csv	169	2026-05-06 → 2026-05-13 (7 dni)

Podział 2 – test na dniach słonecznych (test w warunkach wysokiej produkcji)

W przypadku predykcji pv zrealizowano:

Z puli dni o najwyższej średniej produkcji (powyżej 85. kwantyla) wybrano losowo po jednym dniu z każdego miesiąca. Te dni stanowią zbiór walidacyjny, a pozostałe dane – zbiór treningowy.

Plik	Wiersze	Opis
dataset_sunny_train.csv	10 709	cały zbiór bez dni słonecznych
dataset_sunny_val.csv	144	6 dni słonecznych × 24h

2. Prognozowanie produkcji PV

Praca znajduje się w notatniku `pv_work/models_pv.ipynb`. Porównano dwa modele uczenia głębokiego oraz przeprowadzono analizę ważności cech (SHAP i LIME).

2.1. Konfiguracja eksperymentu

Parametr	Wartość
Okno wejściowe (lookback)	48 godzin
Horyzont prognozy	24 godziny
Liczba cech wejściowych	177
Skalowanie	StandardScaler
Sekwencje	metoda przesuwnego okna (sliding window)

Dane przekształcono do postaci sekwencji `(liczba_okien, 48, 177) → (liczba_okien, 24)`.

2.2. Modele


Zaimplementowano dwa modele od podstaw w PyTorch:

TSMixer – architektura oparta wyłącznie na warstwach MLP. Liczba parametrów: **461 742**.


PatchTST – architektura oparta na transformerze. Liczba parametrów: **200 408**.

Trening wykorzystuje optymalizator AdamW, harmonogram cosine annealing, funkcję straty MSE oraz wczesne zatrzymanie (early stopping).

2.3. Wyniki – walidacja na ostatnich 7 dniach




Dla prognozy krótkoterminowej (h=1, z godzinny wyprzedzeniem) TSMixer wykazuje wysoką precyzję, poprawnie wychwytując punkty zwrotne (spadek produkcji o zmierzchu, wzrost o poranku). Natomiast w prognozie dzień w przód (h=24) pojawiają się znaczne rozbieżności (wysoki błąd MAPE ok. 300%).



Model PatchTST lepiej radzi sobie z długim horyzontem (h=24) – linia predykcji dużo dokładniej odwzorowuje rzeczywistą produkcję (Należy popatrzeć na wartości na osi y).

Tabela metryk (walidacja 7-dniowa):

Model	MAE	RMSE	sMAPE (%)	R ²	Skill Score	MAE dzień	MAPE dzień (%)	R ² dzień
Persistence (baseline)	3863	5079	151.0	−0.97	0.00	4114	356.0	−1.24
TSMixer	1355	1834	99.2	0.74	0.65	1703	79.4	0.60
PatchTST	776	1247	89.2	0.88	0.80	1078	39.2	0.80




Wnioski:


- PatchTST lepiej poradził sobie z zadaniem (niższe MAE/RMSE, wyższy Skill Score 0.80).
- Wysoka wartość MAPE wynika z porównań do produkcji bliskiej zeru w godzinach nocnych – dlatego raportujemy też metryki liczone tylko dla godzin dziennych (MAPE dzień, R² dzień).
- Skill Score > 0 oznacza, że oba modele są lepsze od naiwnego baseline (persistence), poza tym widać to na wartościach również innych metryk.

2.4. Analiza ważności cech – SHAP na lepszym modelu PatchTST

Globalna ważność cech wg SHAP (najważniejsze 25 cech):




Analiza SHAP pokazuje, które cechy najsilniej wpływają na prognozę. Wśród najważniejszych znalazły się agregaty krajowe (m.in. odchylenie standardowe temperatury gleby i promieniowania słonecznego) oraz cechy czasowe (*month_cos*, *dayofyear_cos*).




W prognozie krótkoterminowej kluczowe znaczenie ma najświeższa dostępna godzina (Lag 0). Wartości głębiej w przeszłości mają mniejszy wpływ jednostkowy, ale model efektywnie agreguje informację z całego 48-godzinnego okna – nie opiera się więc na naiwnej ekstrapolacji ostatniego punktu, lecz wykorzystuje szerszy kontekst meteorologiczny i dobową cykliczność.

2.5. Analiza ważności cech – LIME oraz porównanie z SHAP

Wyjaśnienia LIME dla wybranych charakterystycznych godzin:




SHAP (global) vs LIME (local avg over 3 cases)



Oba podejścia (globalne SHAP i lokalne LIME) wskazują zbliżony zestaw najważniejszych cech – zwłaszcza krajowe odchylenia standardowe temperatury gleby, promieniowania słonecznego i wilgotności powietrza, co wzmacnia zaufanie do interpretacji modelu.

2.6. Wyniki – walidacja na dniach słonecznych

W tym teście modele wytrenowano od nowa na zbiorze pozbawionym dni słonecznych, a następnie wykonano prognozę day-ahead (48h kontekstu → 24h prognozy) dla każdego z 6 wybranych dni.




Krzywe uczenia mają zbliżony kształt do walidacji 7-dniowej, natomiast wartości metryk poprawiły się znacząco, szczególnie dla TSMixer.

Tabela metryk (dni słoneczne):

Model	MAE	RMSE	sMAPE (%)	R ²	Skill Score	MAE dzień	MAPE dzień (%)	R ² dzień
Persistence (baseline)	3896	5675	134.7	-0.89	0.00	6032	100.0	-2.70
TSMixer	835	1117	92.5	0.93	0.79	994	57.5	0.88
PatchTST	581	838	84.0	0.96	0.85	777	27.2	0.92

Prognozy dla poszczególnych dni słonecznych:



Wnioski:

- Względem walidacji 7-dniowej widać wyraźną poprawę – zwłaszcza współczynnika R^2 (momentami powyżej 0.9). Wynika to ze specyfiki dni bezchmurnych: mają one silną, stabilną zmienność dobową (od zera w nocy do maksimum w południe), którą model dobrze odwzorowuje.
- Mimo wysokiego R^2 , bezwzględne błędy (MAE) w godzinach szczytu pozostają duże ze względu na dużą skalę generowanej mocy.
- Podwyższone MAPE dla PatchTST wynika z błędów w godzinach nocnych, gdzie produkcja jest bliska zero – nawet niewielki błąd bezwzględny daje ogromny błąd procentowy.
- Również w tym teście **PatchTST okazuje się lepszy** – architektura oparta na transformerze lepiej radzi sobie z długim horyzontem ($h=24$) niż TSMixer.

2.7. Podsumowanie części PV

Spośród dwóch przetestowanych architektur **PatchTST konsekwentnie osiąga lepsze wyniki** w obu scenariuszach walidacji. Oba modele wyraźnie przewyższają naiwne baseline. Analiza SHAP i LIME potwierdza, że model wykorzystuje sensowne cechy (promieniowanie słoneczne, cechy czasowe, krajowe agregaty pogodowe) oraz pełen kontekst 48-godzinne okna.

3. Prognozowanie produkcji wiatrowej (FW)

Ta część zostanie uzupełniona.